ParaMeld 补充实验材料

Chenyang Song

1 组件比较的完整记录

相对 MFU 为各模型相对完整系统比值的平均值，吞吐提升以默认配置为参照。训练次数与 GPU 费用按达标搜索计算，各设置的费用样本数量由达标次数给出。

表 S1 三个代表模型上的归档智能体组件消融。

方法	相对 MFU	提升 (%)	达标次数	训练次数	GPU 小时
完整系统	**1.000**	**+11.7**	**9/9**	**5.3**	**2.44**
无独立分析角色	0.951	+6.2	4/9	8.0	3.52
确定性搜索	0.938	+4.8	3/9	10.0	4.42
单智能体	0.933	+4.3	2/9	9.5	4.18
无执行证据	0.917	+2.5	0/9	N/A	N/A

每设置包含 3 个模型和 3 个种子，提升为全部 9 次搜索的均值。训练次数与 GPU 小时按达标搜索求平均，N/A 表示没有达标搜索。

确定性参考固定全局并行、VPP、微批和重计算，采用相邻边界移动。各项最多 12 次训练尝试，每设置包含 3 个模型各 3 个种子，共 45 次搜索。

2 固定代理求解与完整执行评价

本节比较固定代理目标下的确定性求解与生成建模程序，每实例运行一次，求解上限 60 秒。生成程序耗时 254.99 秒，逐例建模、求解与核验费用见表 S2。

表 S2 相同固定代理与候选空间下的联合优化。

实例与范围	确定性 (ms)	生成求解器 (ms)	确定性 (s)	生成求解器 (s)
MiMo，全范围	1618.966	1884.622	15.07	60.19
Qwen3-14B，全范围	1460.435	1460.435	0.35	2.66
MiMo，固定 $b_7 = 30$	2007.123	2057.051	4.69	60.46

毫秒为归档成本下的迭代目标，秒数包括建模、求解及求解限额之外的核验。每实例运行 1 次，没有新增 GPU 训练。确定性结果均为代理最优；生成求解器在 Qwen 上最优，在 MiMo 上返回可行结果。

另一项 90 秒比较中，两种方法达到相同代理最优值，生成与求解合计 58.88 秒，数值方法 9.07 秒。

三项完整布局均包含 1545 项任务与 448 项 P2P 发送。

3 开放父策略的调查比较

本节比较开放父策略条件下的调查控制，分别采用 180 秒与 120 秒预算。

两种方法共享对应历史、原生域和数值工具。新增 91 次预测与 10 次响应，调用平均等待 116.17 秒，全部计入 180 秒预算。取得 1450.68 毫秒的候选使用 VPP2，其余两次 Agent 保留 VPP1。

表 S3 Qwen3-14B 完整布局的执行评价。局部工作量为最大阶段逐模块前后向成本之和，峰值为显存模型预测。

完整布局	局部/ms	P2P 发送	通信暴露/ms	DAG/ms	峰值/GiB
[5, 5, 5, 5, 5, 5, 5, 5]	55.37	448	10.42	1534.47	24.60
[4, 6, 5, 5, 5, 5, 6, 4]	63.06	448	14.90	1488.96	21.80
[3, 7, 5, 5, 5, 5, 5, 5]	71.03	448	10.54	1533.69	24.40

表 S4 同一历史追加 180 秒的独立搜索（DAG 预测，ms）。最后一列为无法排序与新增配置数；计数含在途评价，最好值仅使用截止前结果。

调查选择	重复 1	重复 2	重复 3	均值 ±s	无法排序/新增
智能体	1494.21	1450.68	1494.21	1479.70 ± 25.13	0/28
确定性规则	1488.81	1488.81	1488.81	1488.81	45/63

表 S5 四模型追加 120 秒的搜索，三次均值与样本标准差（DAG 预测，ms）。

模型	组合智能体	确定性组合选择
Qwen3-14B	1488.81	1488.81
MiMo-7B	2537.38	2537.38
Falcon-H1-7B	1292.06	1263.64 ± 24.61
Nemotron-H-4B	1301.05 ± 53.73	1320.96

Nemotron 使用 8 卡，其余 16 卡；全部复用已有 PVC 成本，新增训练与 GPU 测量均为零。容量未知单独保留。MiMo 一次智能体在 72.17 秒因上下文限额结束，保留此前结果与费用，纳入三次统计。

计入 Qwen 与 MiMo 的串行 Agent 后，共 30 项搜索、457 次新增预测、26 次调用尝试与 22 次响应。Nemotron 两项固定 VPP4 布局在关闭和开启 P2P 重叠时，预测分别为 1293.08/1266.98 和 1377.84/1351.39 毫秒。

4 评价时机的完整数值

共同 Qwen 调查固定 2000 次扩展、宽度 4 和最多 4 次新增完整预测，各规则运行一次。搜索总限额 120 秒，30 秒后停止接纳新工作，在途工作完整计费。

表 S6 共同真实调查中的完整查询时机。毫秒为预测时间；深度表示首次新增完整查询。

规则	首次深度	20 秒/ms	完成后/ms	早期保留替换
晚期轮换	13	1488.81	1488.81	0
固定深度配对	4	1489.52	1372.97	0
早期逐项评价	2	1488.81	1488.81	0
全部早期配对	2	1534.27	1488.81	0
预留末端配额的配对	2	1534.27	1372.97	0
仅末端配对	16	1372.97	1372.97	0
物理阶段再次使用时配对	9	1467.03	1372.97	1

本项历史有一个相容完整后续来源。深度 9 的一次比较将 1511.27 毫秒的保留前缀替换为 1467.03 毫秒的待删除前缀；已测并集最好 1372.97 毫秒布局的前缀在晚期轮换中保留到深度 15，末端被删除。已完成评价的完整候选独立参与最终选择。

5 调查接口与复现设置

本节对应前缀引擎的执行条件对照，包含四模型 24 次开放父策略搜索与 Nemotron 的 6 次固定父策略搜索，共 30 次。模型为 `gpt-6.1-sol`，推理等级为 `low`，通过 Codex 调用，未额外设置采样温度。输入采用相同历史档案，首次响应提出 2 至 4 项具有不同执行依据的调查。单次搜索最多 12 次调用，实际数量见表 S8。

表 S7 实际联合调查的输入、输出与执行约束。

对象	主要内容	处理方式
模型与结构证据	有序模块身份、类型、首尾任务及逐模块成本	引用已有模块；共同负载与后端约束固定
历史父策略	原始配置、最好两项与最近两项候选	以登记身份引用；其余历史可通过工具查询
执行反馈	Rank 占用、通信、容量、成本缺项与保留变化	关联具体候选和成本来源，保留未知状态
调查范围	父策略、模块集合、并行及 P2P 范围	全范围使用空模块列表；局部范围保持其他归属
调查配额	候选、扩展、宽度、完整评价和秒数	受申请、全局剩余额度与实际费用共同限制
生成依据	假设、预期执行变化、副作用及证据引用	保存原始输出，控制器展开结果另行登记
执行核验	Schema、原生合法性、实际继承与成本身份	无效请求返回具体原因；VPP1 按原生规则关闭 P2P 重叠

每个深度在同一端点及执行条件内按宽度限制保留前缀，宽度 4 作用于各分组。完整接续通过正长度、切分粒度、固定模块归属与执行身份核验后才参与预测。预测缓存与新调用分别记录。超时返回已完成候选，在途工作计费；截止后完成的结果不进入截止时刻的最好值。提示词和完整生成响应随复现材料提供。

6 前缀引擎的实际搜索费用

表 S8 按三次独立搜索统计执行条件对照的费用。实际时间包含在途工作的完成费用，因此可能超过 120 秒接纳期限；最终性能使用期限内完成的候选。查询列统计新增预测，缓存查询的时间已包含在实际时间内。这 30 次执行条件对照合计 16 次模型调用和 531 次新预测。开放父策略组合调查及其串行 Agent 扩展、正文 48 次完整重构搜索各自独立统计。

7 相关方法的具体规划对象

8 一次真实响应及其数值执行轨迹

本节对应固定父策略 Nemotron-H-4B 的重复 1，使用 8 张 GPU、TP2/PP4/DP1/VPP2、BF16、序列 2048、全局批 16、微批 1，不使用重计算，P2P 重叠保持开启。模型包含 24 个 Mamba2、24 个 MLP 和 4 个 Attention 模块，初始区间为 $[7, 7, 7, 7, 6, 6, 6, 6]$，初始 DAG 时间为 1671.00 毫秒。

Agent 实际输入包含模块 21 前向 4.6915 毫秒、模块 26 反向 4.1744 毫秒，覆盖 46 至 51 的末端前向任务约 31.27 毫秒，以及 Rank6 计算占用 1590.70 毫秒。原始响应提出三项调查：全模块 PP2/VPP2、全模块 PP4/VPP4，以及保留原形状并开放模块 20 至 28 和 40 至 51。其余模块和运行条件由共同父策略约束。表 S10 按控制器的实际执行顺序列

表 **S8**　前缀引擎同预算比较的实际费用。次数为三次总数，时间为每次搜索平均秒数。

模型与条件	选择器	调用次数	新增预测	调用等待/s	实际时间/s
Qwen3-14B，开放	智能体	3	29	53.81	122.94
	确定性	0	40	0.00	125.51
MiMo-7B，开放	智能体	3	27	46.40	120.70
	确定性	0	58	0.00	127.32
Falcon-H1-7B，开放	智能体	3	45	51.19	120.31
	确定性	0	76	0.00	123.07
Nemotron-H-4B，开放	智能体	4	27	63.91	121.13
	确定性	0	95	0.00	122.54
Nemotron-H-4B，固定	智能体	3	36	48.09	121.27
	确定性	0	98	0.00	122.52

表 **S9**　相关自动并行方法与 ParaMeld 的规划机制。文献条目见正文。

方法	规划对象	代价与求解机制	搜索控制
Alpa	算子内部切分与算子之间阶段安排	算子切分优化、阶段剖析与动态规划	分层数值规划
Galvatron	混合并行、层分配和批大小	实测成本与动态规划	约束过滤和数值搜索
Mist	并行配置、显存管理与状态安排	符号代价分析、Pareto 筛选与混合整数优化	利用资源结构分解搜索
AdaPipe	流水线分区及激活重计算	层级成本分析与重计算代价评价	分区与重计算共同优化
ParaMeld	父策略、完整布局、并行及运行条件	原生约束、执行路径引导的边界重构与微批 DAG 回放	智能体选择调查及布局种子，完整评价更新中心与路径

出结果；本次只有一次真实 Agent 响应。

表 **S10**　同次 Agent 提议与控制器续接的实际记录。性能为 DAG 预测，发现时间从本轮追加搜索开始计算。

执行来源	实际调查	新预测	最好预测/ms	首次发现/s
同次响应	PP2/DP2/VPP2，全模块	1	缺少完整成本	—
同次响应	PP4/DP1/VPP4，全模块	3	1326.11	59.08
同次响应	原 VPP2，开放 20–28、40–51	3	1377.59	66.12
控制器续接	继续同一 VPP4 提议	3	1211.54	80.55
控制器续接	再次执行同一 VPP4 提议	3	1246.15	102.14

取得 1211.54 毫秒的完整区间为 $[3, 4, 5, 4, 3, 3, 3, 3, 3, 3, 4, 3, 5, 3, 2, 1]$。并行范围、局部模块和初始配额来自同次 Agent 响应，完整边界由条件分区器生成，时间由共同 DAG 计算。

9　多维并行配置的已有 GPU 测量

表 S11 列出 Qwen3-8B 的两组独立负载。8 卡组固定序列 2048、GBS16、MBS1、BF16 和完全重计算，采用相同训练入口代码，每项预热 5 次、测量 10 次，独立运行一次。12 卡组固定序列 1024、GBS16、MBS1、TP1/PP6，使用相

同入口与启动脚本的重复 2 至 5，每项预热 20 次、测量 100 次。两组负载分别比较。

表 **S11**　已有并行配置的完整 Rank 计时。12 卡吞吐为 4 次运行均值及样本标准差，显存为最大峰值分配。

GPU	TP	CP	PP	VPP	DP	P2P 方式	吞吐 (token/s)	GiB
8	1	1	8	1	1	无重叠	12767.86	28.79
8	2	1	4	1	1	无重叠	12029.35	22.33
8	2	1	2	1	2	无重叠	12069.75	27.06
8	4	1	2	1	1	无重叠	9155.40	19.33
8	4	1	1	1	2	无流水线传输	8554.30	26.69
8	8	1	1	1	1	无流水线传输	5678.54	19.17
12	1	1	6	1	2	批量，无重叠	13394.00 ± 11.90	26.82
12	1	1	6	3	2	重叠	13994.39 ± 66.24	29.08
12	1	2	6	1	1	批量，无重叠	10748.91 ± 63.53	24.12
12	1	2	6	3	1	重叠	13018.44 ± 39.61	26.11

8 卡组按上述顺序使用完整区间 [5, 5, 5, 5, 4, 4, 4, 4]、[9, 9, 9, 9]、[18, 18]、[18, 18]、[36] 和 [36]。12 卡组的 CP 变化同时改变 DP，VPP 变化同时改变原生 P2P 设置，其差值表示这些配置的联合效果。8 卡组的 GPU 型号及底层软件版本字段缺失，保留相同入口、检查点、数据和负载条件。

复现数据提供 22 项源目录的全部 Rank 计时和配置字段。历史完整 Rank 计时中，170 项标记为 `formal`，其他运行模式分别保存。

10　条件分区的配对候选保留

完整策略生成调用条件分区工具时，可按下列规则在共同合法后续下比较竞争状态。该工具作用于给定全局执行条件，实际调用时机和费用保留在各次调查记录中。

算法 S1 有预算的共同后续配对保留

输入： 同端点状态集合 S、宽度 w、后续来源、当前执行条件与配额

按局部成本排序，暂存前 w 项
if $|S| > w$ 且本阶段尚有配对预算 **then**
    选择第 w 与第 $w+1$ 项，查找两者共同合法后续
    接续两项完整布局，核验归属、执行身份及容量下界
    复用相容报告或调用完整 DAG，记录实际费用及完成时刻
    if 两项时间均可用且后一项更小 **then**
        以后一项替换保留边界处状态
    end if
    保存比较条件、完整预测与实际保留决定
end if
记录保留前缀、删除数量和是否已经取得完整评价
return 保留状态及未解决的评价条件

11 前缀引擎的共同执行条件对照

本节评价前缀构造引擎的调查选择与候选保留，与正文完整重构算法的 48 项研究分别统计。四模型各采用两种选择器、三次重复；Nemotron 另采用固定共同父策略与运行参照，增加六项搜索，共 30 项。训练负载、模块成本与费用规则保持各配对内一致。

30 项搜索共执行 241 次条件分区，其中 200 次的前缀配对配额为零。79 次可用完整配对包含 10 次部分前缀比较；19 次实际保留替换均发生在完整布局深度。这些统计刻画有限查询配额在不同分区深度的实际使用情况。

表 S12 前缀引擎在 120 秒内发现的最好策略，单位 ms，三次均值与样本标准差。

模型与执行条件	智能体选择	确定性选择
开放父策略与 P2P 选择		
Qwen3-14B	1442.25 ± 57.04	1475.19
MiMo-7B	2537.38	2537.38
Falcon-H1-7B	1292.06	1292.06
Nemotron-H-4B	1289.37 ± 38.69	1282.55
固定共同父策略与运行参照		
Nemotron-H-4B	1264.19 ± 59.76	1324.99

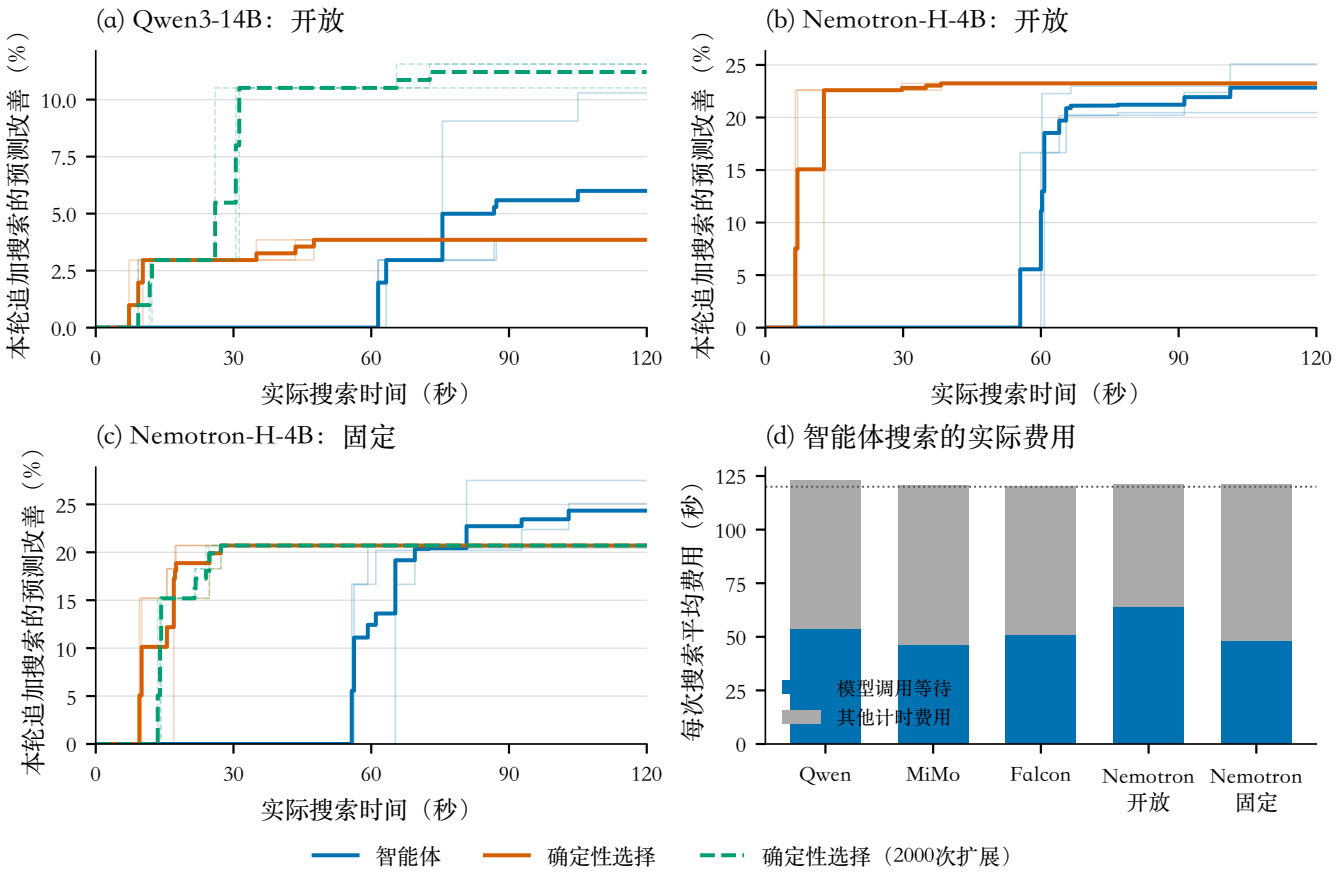


图 S1 前缀引擎的搜索质量与费用。前三个面板报告产生改善的条件，各含三次重复及均值；MiMo 与 Falcon 保留初始最好值，结果见表 S12。末端面板报告调用等待及其他费用。绿色虚线表示每项 2000 次扩展的确定性参考，其 Qwen 结果为 1362.28±9.25 ms。

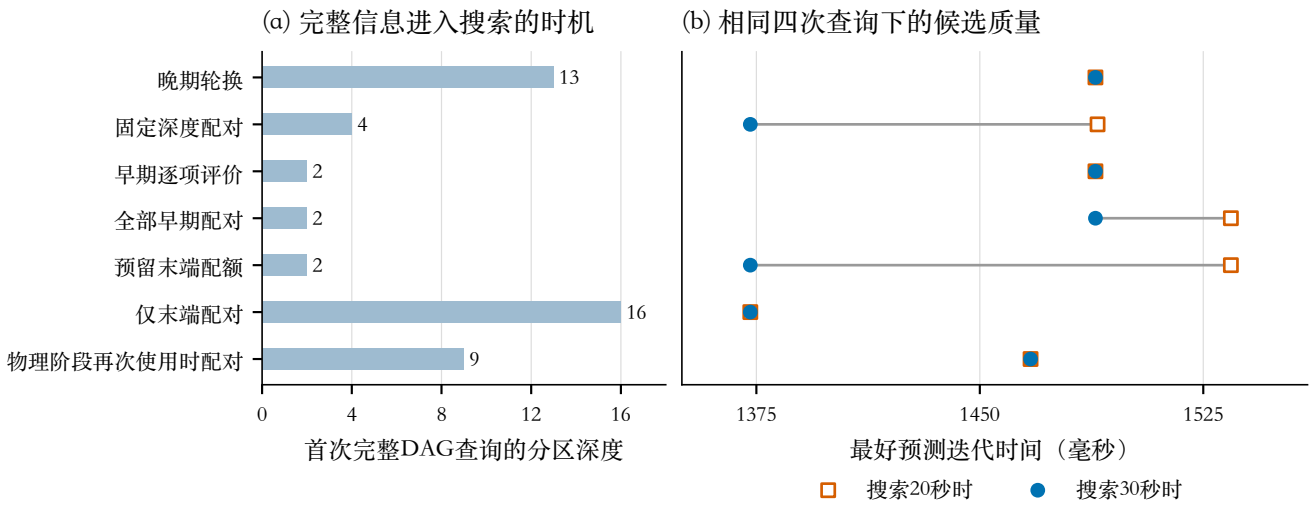


图 **S2**　固定 Qwen PP8/VPP2 前缀调查的七种查询安排。每项最多四次新增完整预测，共同使用 2000 次扩展与宽度 4。左图为首次查询深度，右图为 20 秒与 30 秒内的最好值。表 S6另列获准工作全部完成后的结果。

晚期规则在深度 13 首次调用 DAG，此前已删除 735 个部分状态实例。物理阶段再次使用时的配对在深度 9 比较 1511.27 与 1467.03 ms，改变一次保留，30 秒内最好值为 1467.03 ms。仅末端配对在 20 秒内已取得 1372.97 ms，预留末端配额在 30 秒内达到相同值。

12　完整重构搜索的实际费用

下表对应正文 48 项搜索。每项模型、选择器和生成目标各重复三次，模型响应与新增预测报告总次数，时间报告每次均值。调用等待、求解、缓存核验与保存均进入实际时间；截止后完成的候选继续计费，正文性能采用 120 秒以前完成的候选。表中路径目标使用依赖及资源次序的路径系数，工作量目标使用最大物理阶段前后向累计成本。

24 批有效调查均由初始调用生成。MiMo 工作量组的一次提议修订增加一次响应；Falcon 工作量组的一次运行因上下文预算耗尽结束，终止前候选纳入统计。Falcon 路径组的三个运行提前结束，实际费用见表 S13。

13　九模型默认策略及启动条件

默认策略覆盖全部九种模型，取自 PVC 中已执行的均匀参考配置，按原始实验角色和模块均匀分配规则确定。全部配置使用 16 张 GPU 和全局批量 16；Qwen3-30B-A3B 使用微批量 2，其余使用微批量 1。表 S14给出完整并行组合与已有吞吐，各项配置保留对应序列长度和运行设置。

MiMo 的默认布局为 [5, 5, 5, 5, 4, 4, 4, 4]，相同代码和负载下的历史候选 [5, 5, 5, 4, 5, 4, 4, 4] 为 15094.02 token/s，增加 2.71%。Falcon 的默认布局为 [6, 6, 6, 6, 5, 5, 5, 5]，相同代码和负载下的历史候选 [4, 6, 6, 6, 6, 6, 6, 4] 为 26744.96 token/s，增加 9.76%。MiMo 每项预热 5 次并测量 10 次，Falcon 预热 10 次并测量 30 次，各配置独立运行一次。

九项默认配置的源记录依次为`PVC-00306`、`PVC-00789`、`PVC-00328`、`PVC-00369`、`PVC-00599`、`PVC-00334`、`PVC-00338`、`PVC-00247` 和`PVC-00105`。完整模块布局、已记录的 ETP、检查点、数据路径、测量协议及源目录随复现材料提供。

默认配置的训练记录与历史追加搜索分别统计。正文 48 次搜索从共同历史档案中的最好可评价策略继续。MiMo 四组方法的三次结果均为 2537.38 ms，新并行条件存在适用成本缺项；该项用于记录覆盖状态。各表中三次结果一致的单元格省略标准差。九模型默认策略的登记及历史训练值不计作随机初始配置实验。

表 S13 完整重构搜索的模型调用、预测与实际费用。

模型	生成目标	选择器	响应次数	新预测	调用等待/s	实际时间/s
Qwen3-14B	路径	Agent	3	21	59.49	125.66
	路径	覆盖	0	36	0.00	131.59
	工作量	Agent	3	21	57.03	127.91
	工作量	覆盖	0	47	0.00	123.26
MiMo-7B	路径	Agent	3	33	56.33	121.19
	路径	覆盖	0	34	0.00	122.86
	工作量	Agent	4	30	61.47	122.33
	工作量	覆盖	0	53	0.00	123.63
Falcon-H1-7B	路径	Agent	3	37	58.34	99.99
	路径	覆盖	0	64	0.00	120.88
	工作量	Agent	3	43	48.82	106.02
	工作量	覆盖	0	94	0.00	120.95
Nemotron-H-4B	路径	Agent	3	58	56.59	123.31
	路径	覆盖	0	77	0.00	122.04
	工作量	Agent	3	56	59.40	118.18
	工作量	覆盖	0	108	0.00	123.76

表 S14 九模型登记的默认策略。全部数值来自对应 PVC 记录；并行组合按 TP/CP/PP/DP/EP/VPP 排列，吞吐单位为 token/s。

模型	序列	并行组合	微批	重计算	吞吐
MiMo-7B	2048	2/1/4/2/1/2	1	完全	14695.75
Qwen3-8B	1024	2/1/4/2/1/3	1	关闭	19618.81
Mistral-NeMo-12B	4096	4/1/4/1/1/2	1	关闭	16639.87
Qwen3-14B	1024	2/1/8/1/1/1	1	完全	10829.35
Qwen3-30B-A3B	1024	1/2/4/2/4/3	2	关闭	2710.38
Moonlight-16B-A3B	2048	2/1/4/2/2/2	1	关闭	20577.95
Nemotron-H-4B	4096	2/1/4/2/1/2	1	关闭	50895.73
Falcon-H1-7B	4096	1/1/4/4/1/2	1	完全	24365.78
Lightning-30B-A3B	4096	2/1/4/2/2/2	1	完全	6161.15

14 其他模型的完整配置与训练记录

14.1 同条件布局比较

以下四组保留相同模型检查点、数据、并行组合、微批、重计算、执行代码与测量窗口，每项配置独立运行一次，均取得 16 个 Rank 的完整计时且两节点正常退出。每项预热 10 次、测量 30 次，全局批量 16；序列长度除 Moonlight 为 2048 外均为 4096。吞吐采用最慢 Rank 的同步窗口，显存采用全部 Rank 的最大已分配显存。

Falcon-H1-7B。

固定 TP1/CP1/PP4/DP4/EP1/VPP2 和微批 1，采用完全重计算、BF16 参数及 FP32 流水线传输。参照布局 $[6, 6, 6, 6, 5, 5, 5, 5]$ 对应 24365.78 token/s 与 22.24 GiB，布局 $[4, 6, 6, 6, 6, 6, 6, 4]$ 对应 26744.96 token/s 与 20.90 GiB，吞吐提高 9.76%。源记录为 `PVC-00247` 与 `PVC-00244`。

表 **S15** Moonlight 执行证据组织的训练测量。吞吐单位为 token/s，费用单位为 GPU 小时。

设置与重复	轨迹状态	初始吞吐	新候选吞吐	活动费用	保留费用
执行视图，1	完成	14427.89	OOM	0.787	4.011
直接记录，1	完成	14427.89	17082.02	1.089	3.922
直接记录，2	完成	14352.01	14907.81	1.545	4.560

Nemotron-H-4B。

固定 TP2/CP1/PP4/DP2/EP1/VPP2 和微批 1，采用 BF16 且关闭重计算。参照布局 [7, 7, 7, 7, 6, 6, 6, 6] 对应 50895.73 token/s 与 18.50 GiB；布局 [7, 7, 7, 7, 7, 7, 8, 2] 对应 58683.34 token/s 与 19.27 GiB，吞吐提高 15.30%。源记录为 `PVC-00338` 与 `PVC-00336`，与正文预热 1 次的另一组记录分别保存。

Lightning-30B-A3B。

固定 TP2/CP1/PP4/DP2/EP2/VPP2 和微批 1，保留 BF16、完全重计算、优化器 CPU 卸载及一个 MTP 模块。参照布局 [7, 7, 7, 7, 6, 6, 6, 6] 对应 6622.13 token/s 与 28.09 GiB；布局 [7, 7, 7, 7, 7, 7, 9, 1] 对应 7577.06 token/s 与 25.17 GiB，吞吐提高 14.42%。源记录为 `PVC-00305` 与 `PVC-00303`。重计算与优化器卸载保持原设置，比较中的修改为完整模块布局。

Moonlight-16B-A3B。

固定 TP2/CP1/PP4/DP2/EP2/VPP2 和微批 1，采用 BF16 且关闭重计算。参照布局为 [4, 4, 4, 3, 3, 3, 3, 3]，吞吐 20577.95 token/s，显存 26.76 GiB。另一项布局 [3, 4, 4, 4, 3, 4, 4, 1] 将末端缩短为一个模块，吞吐 19379.50 token/s，显存 28.77 GiB，吞吐下降 5.82%。源记录为 `PVC-00334` 与 `PVC-00335`。在该执行条件下，末端减负伴随其他阶段新增工作与存储，因此布局选择使用完整迭代评价。

14.2 FP16 计算与 FP32 优化器状态的联合策略

本组固定 16 张 GPU、序列 2048、全局批量 16、FP16 参数，以及 FP32 主参数副本、主梯度和 Adam 一阶、二阶状态。各模型从本次随机合法配置开始，未向 Agent 提供以前的最好策略。Agent 采用`gpt-5.6-sol/medium`，各轮可以读取本次已产生的策略及反馈。每项配置预热 5 次、测量 30 次成功更新，全部 16 个 Rank 的更新状态和有限数值检查通过。各项结果为对应完整配置的一次测量。

表 S16给出四组关键配置，吞吐、显存与 MFU 见正文表 4。全部配置保持 CP1、P2P 重叠关闭和原始物理 Rank 映射，使用 Megatron DDP 及分布式优化器，优化器 CPU 卸载比例为 0。MiMo 的 VPP2 配置采用微批分组 2。候选编号连接实际 Agent 提议、选择记录和逐 Rank 测量。

15 执行证据组织的训练对照

本项固定 Moonlight、每组共同初始策略、源码、可用工具与三轮决策，比较结构化执行视图和直接记录两种上下文组织。表 S15报告三条完成轨迹的新增候选测量及费用。GPU 活动费用包括训练、加载与剖析；资源保留费用另计智能体调用、工具操作和结果收集期间的 16 卡占用。

首条执行视图轨迹完成两项加载验证，完整测量候选发生 CUDA OOM，搜索结果保留初始完整配置。首条直接记录轨迹选择 TP1/PP8/DP2/VPP2、微批 1、完全重计算及 16 个虚拟分块。第二条采用 TP2/PP2/DP4、EP4/ETP1 和 VPP2，微批为 1，并使用完全重计算与 P2P 重叠。未完成轨迹不纳入本表，执行记录与已发生费用保留于数据附件。

表 S16 四模型训练实验的关键配置。并行组合按 TP/PP/CP/DP/EP/ETP/VPP 排列，MBS 表示微批大小，模块布局保持模型原始顺序。

模型	策略	并行组合	MBS	模块布局	重计算
MiMo-7B	初始	2/2/1/4/1/2/1	1	[18, 18]	完全
	ParaMeld	2/2/1/4/1/2/2	1	[9, 9, 9, 9]	注意力核心
Qwen3-8B	初始	8/2/1/1/1/1/1	1	[18, 18]	完全
	ParaMeld	4/2/1/2/1/4/1	1	[18, 18]	注意力核心、MLP
Qwen3-14B	初始	1/8/1/2/1/1/1	1	[5, 5, 5, 5, 5, 5, 5, 5]	完全
	ParaMeld	4/4/1/1/1/4/1	1	[10, 10, 10, 10]	注意力核心、MLP
Moonlight	初始	1/8/1/2/1/1/1	1	[4, 4, 4, 3, 3, 3, 3, 3]	完全
	ParaMeld	1/8/1/2/1/1/1	2	[3, 4, 4, 4, 3, 3, 3, 3]	完全

表 S17 Qwen3-14B 训练轨迹的布局与测量。各行对应完整运行，最后一行为同一联合策略的独立重复。

策略	模块布局	重计算	吞吐 (token/s)
初始配置	[5, 5, 5, 5, 5, 5, 5, 5]	完全	11903.36
分区父策略	[3, 6, 6, 5, 5, 5, 6, 4]	完全	12608.80
Agent 联合策略	[3, 6, 6, 5, 5, 6, 5, 4]	选择性 MLP	13980.51
同策略重复	[3, 6, 6, 5, 5, 6, 5, 4]	选择性 MLP	14043.38

16 联合策略的关键配置

17 执行证据驱动的训练策略修订

本例采用 Qwen3-14B、16 卡、FineWeb、序列 2048、全局批 16、微批 1 和 BF16，固定 TP2/PP8/DP1/VPP1。各项预热 5 步、测量 30 步，智能体为 `gpt-5.6-sol/medium`。分区父策略完成测量后，智能体提出重计算、微批与 TP/PP 的关联调查，并查询区域 5 至 7 的反向执行。

查询返回区域 6 部分反向任务为 82.59 ms，相邻区域 5 和 7 分别为 68.66 与 70.90 ms，并包含跨微批计算依赖。智能体将模块 30 由区域 6 交给区域 5，同时调整 MLP 重计算，得到表 S17中的联合策略，峰值显存为 20.50 GiB。微批 2 与 TP4/PP4 的另外两项调查缺少匹配成本，独立登记其测量需求。

受控扩展进一步比较同一布局的重计算设置。关闭重计算后的两次平均吞吐为 17138.59 token/s，显存为 27.22 GiB；VPP2 无重计算配置发生 OOM。这些扩展与 Agent 原始提议分别记录。

18 执行路径与联合边界的具体案例

Qwen3-14B 的 CPU 搜索固定 16 卡、TP2/PP8/DP1、CP1、序列 1024、全局批 16、微批 1、BF16 和完全重计算。初始 VPP1 布局 [5, 5, 4, 6, 5, 5, 5, 5] 预测 1534.27 ms。一次 `gpt-6.1-sol/low` 调用开放模块 30、31、34、35、36，生成 [5, 5, 4, 6, 5, 6, 5, 4]，并提出 VPP2 及 PP2/DP4 调查。

Agent 布局预测 1499.94 ms，同一授权范围内的路径求解产生 [5, 5, 4, 6, 5, 5, 6, 4]，预测 1494.21 ms。VPP2 参照布局为 [3, 3, 3, 3, 3, 3, 3, 3, 2, 2, 2, 2, 2, 2, 2, 2]，预测 1488.81 ms。路径求解随后生成

$$\mathbf{x} = [2, 4, 3, 3, 3, 3, 3, 3, 2, 2, 2, 2, 2, 2, 3, 1],$$

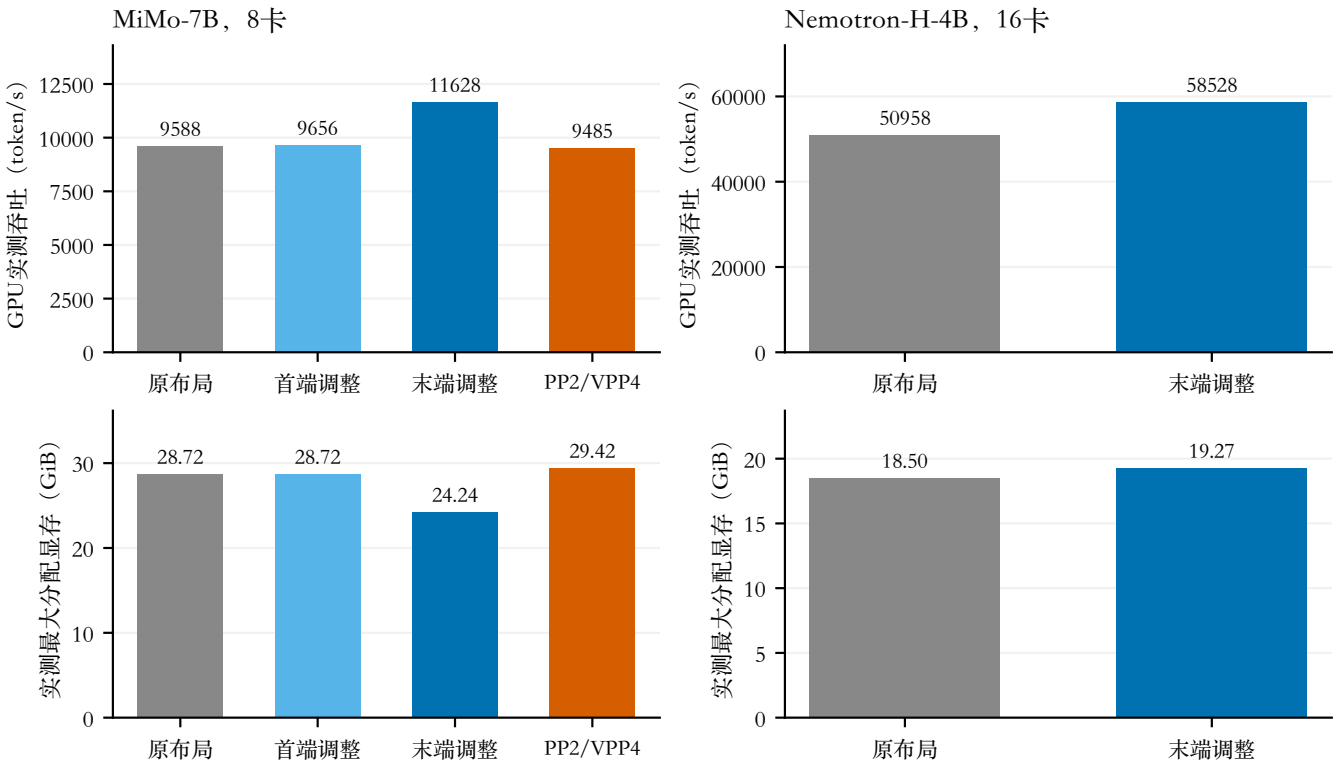


图 **S3**　历史布局的吞吐与显存测量。两组数据采用各自的固定负载与测量窗口，具体协议见本节。

并于 108.99 秒得到 1448.78 ms。物理阶段模块数变为 [4, 6, 5, 5, 5, 5, 6, 4]。同次确定性路径搜索也取得该时间；PP2/DP4 调查返回同步成本需求。

Nemotron-H-4B 使用 TP2/PP4/DP1/VPP2、52 个异构模块且关闭重计算。初始物理阶段 3 持有模块 21 至 27 和 46 至 51，Rank6 计算占用 1590.70 ms。一条最长参照路径的前后向出现次数均为 (1, 1, 1, 16, 0, 0, 0, 16)。模块 21 从 V3 迁至 V2、模块 27 从 V3 迁至 V4、模块 46 从 V7 迁至 V6 的单步路径代理变化分别为 −100.425、−105.296 和 −83.808 ms，完整候选继续通过全图回放评价。

19　历史布局测量与流水线示意

图 S3保留两组历史布局测量。MiMo 使用 8 卡、TP2/PP4/DP1/VPP2、序列 2048 和完全重计算，预热 2 次、测量 3 次；Nemotron 使用 16 卡、TP2/PP4/DP2/VPP2、序列 4096 和无重计算，预热 1 次、测量 30 次。各组固定全局批 16 及微批 1，每项配置独立运行一次。

图 S4来自另一组 MiMo 配对测量，采用 16 卡、TP2/PP4/DP2/VPP2、序列 2048、全局批 16、微批 1 和完全重计算，预热 5 次、测量 10 次。图中标注的迭代时间为 2230 与 1925 ms，任务宽度用于示意执行次序。

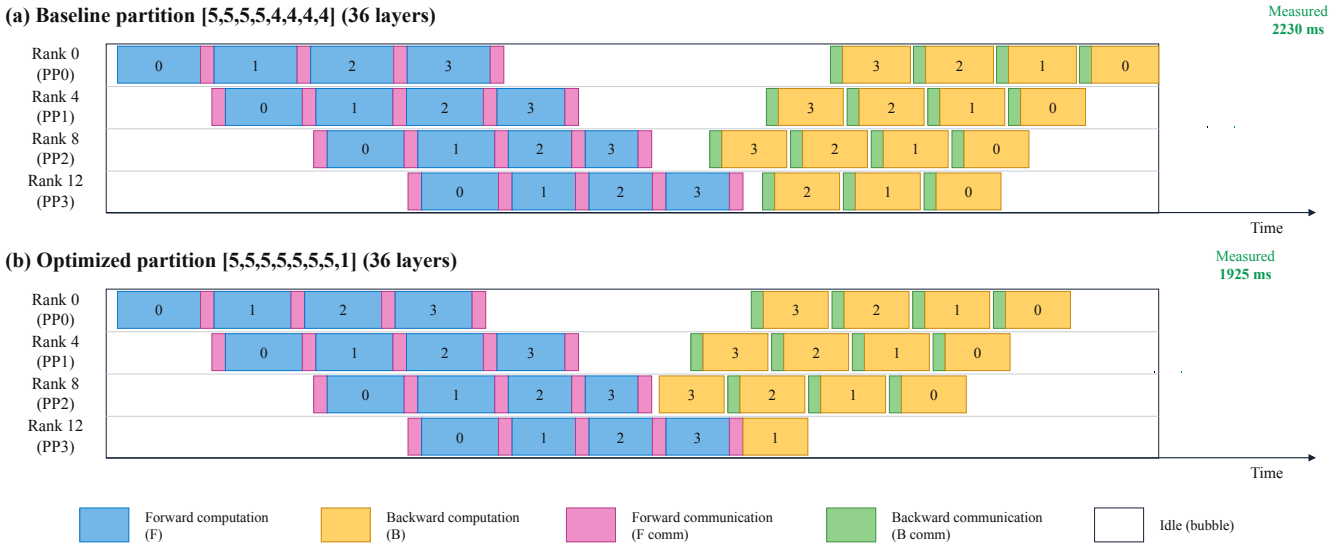


图 **S4**　MiMo 重新分区前后的流水线执行示意。标注为该组配对运行的实测迭代时间。